CS-NAS: búsqueda evolutiva de arquitecturas federada con muestreo estratificado por clusters de similitud

Informe experimental final (resultado mayormente negativo)

Proyecto EvoFederated

21 de octubre de 2026

Resumen

Se propuso y evaluó CS-NAS, un algoritmo evolutivo de búsqueda de arquitecturas en aprendizaje federado non-IID con muchos nodos. Los nodos se agrupan una sola vez por similitud de las actualizaciones de un modelo sonda; en cada generación se elige un representante al azar por cluster, esos representantes entrenan cada arquitectura candidata con FedAvg y otro miembro del mismo cluster, que no entrenó, la evalúa. El fitness es la accuracy estimada y el número de parámetros. Se midió: (i) la calidad del estimador de fitness, (ii) la calidad de los frentes de Pareto encontrados frente a muestrear nodos al azar y frente a búsqueda aleatoria, (iii) el ruido del fitness y (iv) un refinamiento multifidelidad. **Resultados.** Evaluar en un nodo retenido del cluster elimina un sesgo optimista y reduce el RMSE del estimador entre 21 % y 48 % según régimen y muestreo (41–48 % con clusters por Δ). Los clusters por Δ aproximan a los formados con las etiquetas reales sin usarlas y tienen menor error de evaluación que muestrear nodos al azar, pero no ordenan mejor las arquitecturas (Kendall τ entre 0.82 y 0.97 en todas las variantes y regímenes, sin diferencias claras entre ellas). En la búsqueda (Fashion-MNIST, $\alpha = 0{,}1$, $N = 100$, $C = 10$, 5 semillas pareadas, igual coste) CS-NAS no mejora el frente: es ligeramente peor que NSGA-II con nodos aleatorios (diferencia de hipervolumen en test $-0{,}009$, intervalo $[-0{,}012, -0{,}005]$, 0 de 5 semillas a favor) y no se distingue de la búsqueda aleatoria con los mismos clusters. Un control añadido (búsqueda aleatoria con nodos aleatorios) muestra que, con muestreo aleatorio de nodos, NSGA-II supera a la búsqueda aleatoria en el área bajo la curva de hipervolumen en 5 de 5 semillas ($+0{,}023$, $[+0{,}016, +0{,}029]$) y por poco en el hipervolumen final de test ($+0{,}008$, $[-0{,}001, +0{,}019]$, 4/5), un efecto pequeño que no aparece con clusters. El diseño solo detectaría efectos mayores que $\approx$5.7 % del hipervolumen en el contraste con clusters. Por nodo, el hall of fame final mejora la accuracy del 60 % de los nodos respecto a la población inicial (empeora el 39 %), sin diferencia clara entre la búsqueda evolutiva y la aleatoria, y aun entrenar con los 100 nodos en vez de 10 deja peor a un tercio de los nodos con $\alpha = 0{,}1$. El cuello de botella es el ruido del fitness: una misma arquitectura cambia $\pm 0{,}06$–$0{,}10$ de accuracy según qué 10 nodos la entrenan, comparable a la banda que separa a las mejores. Subir C a 20 reduce ese ruido a menos de la mitad, y reevaluar candidatos con más nodos mejora el hipervolumen final como máximo en $\approx$1 %. Se concluye que, en el régimen probado, la estratificación por similitud no aporta a la búsqueda, y que la evolución aporta a lo sumo una mejora pequeña y solo con muestreo aleatorio de nodos. El aporte es el diagnóstico y las piezas reutilizables (evaluador retenido, estimador, análisis de ruido), no un método ganador.

1. Contexto y objetivo

Entrenar y evaluar muchas arquitecturas candidatas en aprendizaje federado es caro, y el coste crece con el número de nodos participantes. La revisión sistemática previa de este proyecto (`manuscript/main.pdf`) y la lectura de texto completo de los estudios más cercanos mostraron que los trabajos de NAS federado que evalúan candidatos con un subconjunto de clientes lo hacen eligiéndolo al azar [1] o formando grupos que igualan la distribución de etiquetas global [2], lo que requiere que los clientes revelen información sobre sus datos; la selección de participantes

por similitud o agrupamiento se evalúa sobre todo para acelerar el entrenamiento de un único modelo [3]. Khodak et al. señalan además que la validación obtenida de pocos clientes es una señal ruidosa [4]. Con ese contexto se propuso CS-NAS, cuyo objetivo es encontrar un frente de Pareto (accuracy frente a número de parámetros) con un coste de evaluación independiente del número de nodos.

Pregunta de investigación. A igual coste de entrenamiento, ¿el muestreo estratificado por clusters de similitud de actualizaciones produce mejores frentes que muestrear nodos al azar, y la búsqueda evolutiva aporta algo sobre muestrear arquitecturas al azar?

Este informe sustituye a las propuestas anteriores del proyecto (disimilitud/similitud con 8 nodos, many-objective), archivadas en la etiqueta de git `legacy-final`, cuyos resultados no mostraban ventaja de ninguna estrategia y cuya comparación estaba confundida (con una ronda, las estrategias de pares usaban solo dos subconjuntos distintos de clientes en 56 evaluaciones).

2. Método: CS-NAS

1. **Sonda (una vez).** Los N nodos entrenan el mismo modelo sonda desde la misma inicialización; solo se envía el vector Δ_i de cada actualización.
2. **Clusters.** k-means esférico sobre los Δ_i normalizados da C clusters $G_1, \ldots, G_C$.
3. **Representantes por generación.** Se sortea un nodo $r_c \in G_c$ por cluster con un RNG derivado de la semilla y la generación; los mismos representantes se usan para toda la población de esa generación.
4. **Entrenamiento y evaluación.** Cada arquitectura se entrena con FedAvg sobre $\{r_c\}$, ponderado por $|G_c|$. Se evalúa en otro nodo $e_c \in G_c \setminus \{r_c\}$ que no entrenó (solo inferencia): $\hat{a} = \sum_c \frac{|G_c|}{N} \operatorname{acc}(e_c)$.
5. **Fitness (minimización).** $(-\hat{a},\ p/p_{\text{máx}})$, con p el número de parámetros y $p_{\text{máx}}$ el de la arquitectura mayor del espacio.
6. **Búsqueda.** NSGA-II [5] que reevalúa padres e hijos con los mismos representantes en cada generación (de lo contrario, fitness medidos con nodos distintos sesgarían la selección). La búsqueda aleatoria recibe el mismo número de evaluaciones por generación.

Monitoreo (solo reporte). El mismo modelo se evalúa en todos los nodos; ese valor nunca entra al fitness ni a la selección (verificado con pruebas unitarias). El coste de búsqueda se mide en entrenamientos locales; el de la sonda (N entrenamientos de una época) se reporta aparte.

Decisión de diseño documentada. Evaluar en el propio representante daba un sesgo optimista de +0.025 a +0.045 en un piloto (el modelo acaba de entrenar con esos datos); por eso se adoptó el evaluador retenido.

3. Protocolo experimental

Datos. Fashion-MNIST y CIFAR-10 particionados con Dirichlet ($\alpha \in \{0{,}1, 0{,}5\}$) entre $N = 100$ nodos; cada nodo reserva el 30 % de su partición para validación; el conjunto de prueba oficial se reparte aparte entre los nodos y solo se lee en la reevaluación final. **Entrenamiento.** FedAvg, Adam, tamaño de lote 32, y la configuración elegida en el diagnóstico de la sección 5.1 (lr 10^{-2}, 2 épocas locales, 20 rondas). **Espacio.** CNN pequeñas: 1–3 bloques convolucionales (8–64 canales, núcleo 3 o 5, ReLU o ELU, BatchNorm, dropout) y pooling global. **Métricas.** RMSE, sesgo y Kendall τ del estimador frente a la accuracy del mismo modelo en todos los nodos; hipervolumen (HV) del frente con punto de referencia fijo ($-\text{acc} = 0,\ p/p_{\text{máx}} = 1{,}05$); el HV principal se mide sobre el frente final reentrenado desde cero con los 100 nodos y evaluado en test. **Réplicas.** 5 semillas de partición pareadas entre métodos (3 en un estudio previo); la

unidad de réplica es la semilla. Los intervalos son bootstrap sobre esas semillas y deben leerse como descriptivos: con $n = 5$ el test de Wilcoxon no puede dar $p < 0{,}0625$.

4. Flujo de cada experimento

Esta sección describe, paso a paso, qué hace cada experimento. Todos comparten la preparación común y difieren en lo que se varía.

Preparación común (una vez por semilla). (a) Se reparte el conjunto de entrenamiento entre los $N = 100$ nodos con Dirichlet(α) y cada nodo separa el 30 % como validación; el conjunto de prueba oficial se reparte aparte. (b) Si el método usa clusters, los 100 nodos entrenan una sola vez, una época, el mismo modelo sonda (dos bloques convolucionales de 8 y 16 canales, núcleo 3, ReLU, BatchNorm) desde la misma inicialización; cada nodo devuelve solo el vector Δ de su actualización y k-means esférico agrupa los vectores en C clusters. La semilla fija la partición, la sonda, el sorteo de nodos y la población inicial. **Cómo se sortean las arquitecturas.** Cada arquitectura es un vector en $[0, 1]^8$ (número de bloques, canales de cada bloque, tamaño de núcleo, activación, dropout y BatchNorm) que se redondea a opciones discretas; este redondeo no es uniforme sobre las opciones (con tres opciones, la central sale el 50 % de las veces y cada extremo el 25 %). La búsqueda aleatoria y la población inicial de NSGA-II sortean los vectores de la misma manera, de modo que la comparación entre ambos es justa, pero "aleatorio" significa sortear en ese espacio continuo y no de forma uniforme entre las combinaciones.

Diagnóstico de entrenamiento

(1) Una arquitectura fija (dos bloques de 16 y 32 canales, núcleo 3, ReLU, sin dropout, con BatchNorm) y una partición. (2) Para cada una de las 40 configuraciones de FedAvg (optimizador, learning rate, épocas, rondas, con o sin BatchNorm, 10 nodos aleatorios o los 100) se entrena el modelo global. (3) Se mide la accuracy media del modelo en la validación de todos los nodos. Sirve solo para elegir un régimen en el que el fitness sea informativo.

Estudio de estimador (E2)

(1) Por cada semilla de partición y cada α se prepara la partición y los clusters (Δ, por etiquetas como oráculo, y una partición aleatoria en C grupos). (2) Se sortean 16 arquitecturas aleatorias, las mismas para todas las variantes. (3) Para cada una de las seis variantes y cada uno de 2 sorteos de nodos: se eligen los nodos de entrenamiento (un representante por cluster, o 10 nodos al azar) y los de evaluación (otro miembro del mismo cluster que no entrenó, o 10 nodos distintos al azar; en las variantes sin retener, el propio representante); cada arquitectura se entrena con FedAvg sobre los nodos de entrenamiento (20 rondas, 2 épocas) y su accuracy estimada es la media ponderada de la accuracy de validación en los nodos de evaluación. (4) El mismo modelo se evalúa en la validación de los 100 nodos (solo diagnóstico). (5) Por semilla y variante se calcula el sesgo, el RMSE y el Kendall τ entre la accuracy estimada y la de todos los nodos; luego se agregan entre semillas y se comparan variantes con diferencias pareadas por semilla.

Búsqueda de frentes (E3): cuatro métodos

Cada método combina un muestreo de nodos y una búsqueda. Por semilla, los cuatro comparten partición, sonda y presupuesto (150 evaluaciones; cada una entrena $C = 10$ nodos durante 20 rondas, es decir 30 000 entrenamientos locales). Para cada generación $g = 0, \ldots, 7$:

1. **Nodos de la generación.** Con un generador derivado de la semilla y de g se eligen los nodos de entrenamiento y de evaluación: *clusters* (un representante por cluster de Δ y otro miembro

del mismo cluster como evaluador) o *aleatorio* (10 nodos de entrenamiento y otros 10 distintos de evaluación). Son los mismos para todas las arquitecturas de esa generación.

2. **Candidatos.** *NSGA-II:* en $g = 0$ se sortean 10 arquitecturas; en $g \geq 1$ se generan unos 10 hijos con cruce SBX y mutación polinómica y se reevalúan junto con los 10 padres. *Búsqueda aleatoria:* se sortean 10 arquitecturas nuevas en $g = 0$ y 20 en cada generación siguiente (el mismo número de evaluaciones que NSGA-II).
3. **Evaluación.** Cada candidato se entrena con FedAvg sobre los nodos de entrenamiento y su fitness es (accuracy estimada en los nodos de evaluación, número de parámetros normalizado). En paralelo, y sin influir en la búsqueda, el mismo modelo se evalúa en todos los nodos para registrar el HV real, el error del estimador y otras métricas por generación.
4. **Selección.** Solo NSGA-II: ordenación por no dominancia y distancia de aglomeración sobre padres e hijos; sobreviven 10.

Tras la generación 7, el frente de salida se toma de todas las arquitecturas evaluadas (no dominadas por accuracy estimada y parámetros), se ordenan por accuracy y se conservan hasta 5; cada una se reentrena desde cero con los 100 nodos (20 rondas, 2 épocas, una inicialización independiente) y se mide la accuracy media por nodo en prueba, de donde sale el HV principal. Los cuatro métodos son: clusters con NSGA-II (la propuesta), nodos aleatorios con NSGA-II, clusters con búsqueda aleatoria y nodos aleatorios con búsqueda aleatoria (el control).

Diagnóstico de ruido

(1) Se fijan 20 arquitecturas aleatorias. (2) Para cada una y cada variante (clusters o nodos aleatorios, con $C \in \{10, 20, 40\}$) se hacen 4 sorteos independientes de los nodos de entrenamiento, se entrena y se mide la accuracy en todos los nodos. (3) Como referencia, cada arquitectura se entrena una vez con los 100 nodos. (4) Se calculan la desviación entre sorteos de una misma arquitectura (ruido), la de las medias entre arquitecturas (señal), el τ entre sorteos y frente a la referencia, el sesgo y el acierto en pares de arquitecturas cercanas.

Refinamiento multifidelidad (E4)

Se aplica después de cada corrida de E3, sin repetir la búsqueda. (1) Se agregan las evaluaciones por arquitectura (media de la accuracy estimada) y se toman las capas no dominadas hasta 12 candidatos. (2) Cada candidato se reevalúa con 40 nodos aleatorios nuevos, independientes de los de la búsqueda, con evaluadores retenidos. (3) El frente final se elige con esa estimación (no dominado, ordenado por accuracy, hasta 5), se reentrena con los 100 nodos y se mide en prueba. El procedimiento es idéntico para los cuatro métodos.

Proporción de nodos que mejoran

(1) Para cada corrida de E3 se toman la población inicial, el hall of fame (frente de Pareto no dominado entre todo lo evaluado) y el frente refinado; las arquitecturas distintas se reentrenan una vez con los 100 nodos (20 rondas, 2 épocas, misma inicialización que la reevaluación final) y se mide la accuracy de cada nodo en prueba. (2) Para el diagnóstico de entrenamiento y el estudio de ruido (10 arquitecturas, 2 sorteos por variante y participación completa) se hace lo mismo en validación. (3) Para cada par de modelos o de conjuntos A y B, y por nodo, se compara la accuracy: mejora, igual o empeora (con la media o la mejor accuracy del conjunto), y se agrega entre semillas, arquitecturas y sorteos.

Análisis sin entrenamiento nuevo

Paisaje: con las evaluaciones guardadas de E3 se mide la dispersión de la accuracy entre arquitecturas, la fracción cercana a la mejor, la varianza que explican los genes (bosque aleatorio

con validación cruzada) y, para las arquitecturas reevaluadas en varias generaciones, la dispersión dentro de cada una. *Clusters:* se reconstruyen los Δ con la misma sonda; se comparan agrupaciones (k-means y enlace promedio sobre Δ, k-means con etiquetas, aleatoria) por tamaños, cohesión de etiquetas y un proxy de la varianza del estimador; la estabilidad se mide repitiendo la sonda con otra inicialización y k-means con otra semilla.

5. Resultados

5.1. El régimen de entrenamiento condicionaba todo

Con Adam 10^{-3}, 2 épocas y 5 rondas (régimen de los primeros estudios) la accuracy media era de apenas 0.18 ($\alpha = 0{,}1$) y 0.26 ($\alpha = 0{,}5$). Un diagnóstico de 40 configuraciones sobre una arquitectura fija (Figura 1) mostró que el learning rate era el factor dominante: con Adam 10^{-2}, 5 épocas y 20 rondas se llega a 0.45 y 0.77. Entrenar con 10 representantes pierde frente a usar todos los nodos cuando la heterogeneidad es alta (0.33 frente a 0.51 con $\alpha = 0{,}1$ y mismo presupuesto de rondas y épocas). Los estudios de estimador previos a este diagnóstico solo tienen valor como historia del proceso: un piloto de 24 evaluaciones sugería una gran ventaja de los clusters por Δ que desapareció con más datos.

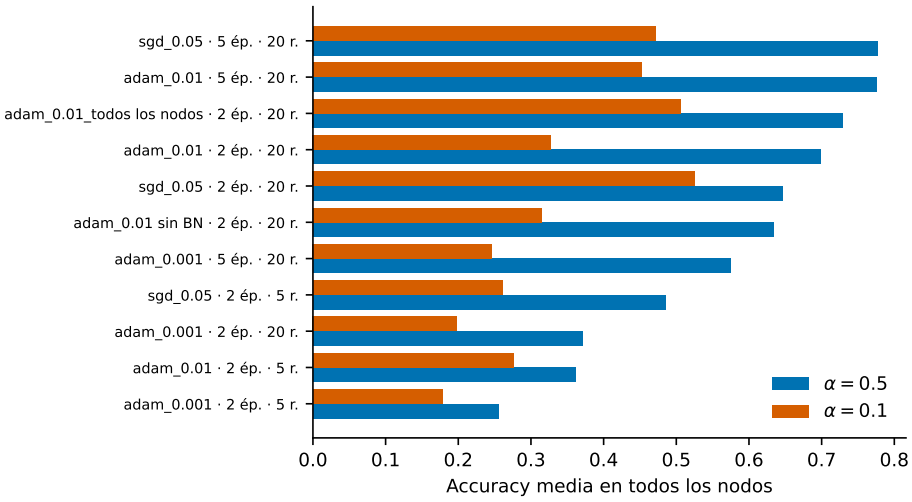


Figura 1: Accuracy media en todos los nodos de una arquitectura fija según la configuración de FedAvg ($C = 10$ nodos aleatorios, salvo "todos los nodos"). Una sola partición.

5.2. Calidad del estimador de fitness

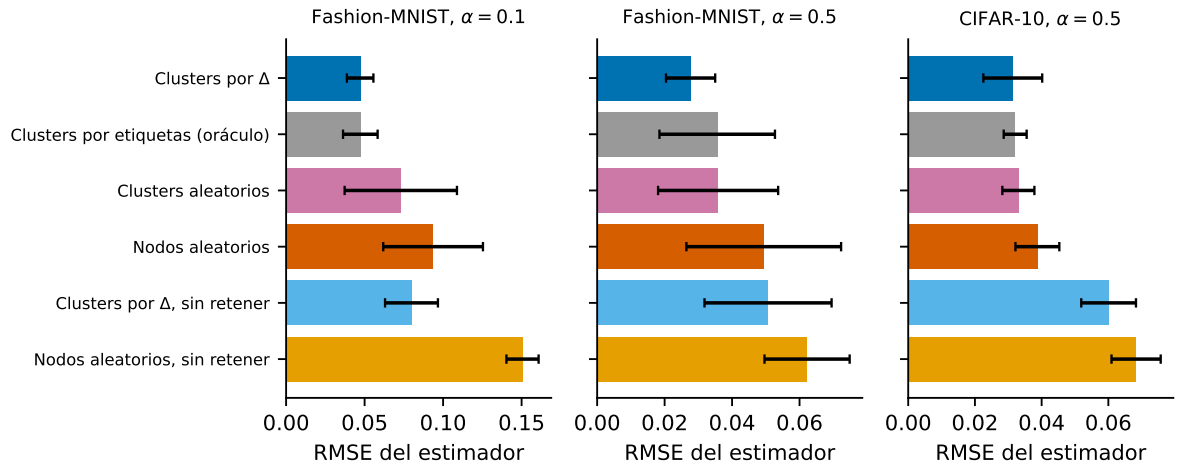


Figura 2: RMSE del estimador por variante y régimen (media ± DE entre semillas; $C = 10$). Fashion-MNIST con Adam 10^{-2} y 20 rondas (5 semillas por α); CIFAR-10 con Adam 10^{-3} y 8 rondas (5 semillas), donde los modelos casi no aprenden (accuracy ≈0.21).

Tabla 1: Estimador de fitness frente a la accuracy del mismo modelo en todos los nodos (media sobre semillas; DE = desviación entre semillas; τ: Kendall dentro de cada sorteo).

Régimen	Variante	Sesgo	RMSE	RMSE (DE)	τ	Semillas
Fashion-MNIST, $\alpha = 0{,}1$	Clusters por Δ	-0.008	0.047	0.008	0.885	5
Fashion-MNIST, $\alpha = 0{,}1$	Clusters por etiquetas (oráculo)	-0.012	0.047	0.011	0.900	5
Fashion-MNIST, $\alpha = 0{,}1$	Clusters aleatorios	-0.001	0.073	0.036	0.886	5
Fashion-MNIST, $\alpha = 0{,}1$	Nodos aleatorios	-0.036	0.094	0.032	0.853	5
Fashion-MNIST, $\alpha = 0{,}1$	Clusters por Δ, sin retener	0.072	0.080	0.017	0.907	5
Fashion-MNIST, $\alpha = 0{,}1$	Nodos aleatorios, sin retener	0.140	0.151	0.010	0.868	5
Fashion-MNIST, $\alpha = 0{,}5$	Clusters por Δ	0.007	0.028	0.007	0.958	5
Fashion-MNIST, $\alpha = 0{,}5$	Clusters por etiquetas (oráculo)	0.003	0.036	0.017	0.957	5
Fashion-MNIST, $\alpha = 0{,}5$	Clusters aleatorios	-0.004	0.036	0.018	0.952	5
Fashion-MNIST, $\alpha = 0{,}5$	Nodos aleatorios	-0.015	0.049	0.023	0.945	5
Fashion-MNIST, $\alpha = 0{,}5$	Clusters por Δ, sin retener	0.044	0.051	0.019	0.948	5
Fashion-MNIST, $\alpha = 0{,}5$	Nodos aleatorios, sin retener	0.053	0.062	0.013	0.972	5
CIFAR-10, $\alpha = 0{,}5$	Clusters por Δ	0.003	0.031	0.009	0.835	5
CIFAR-10, $\alpha = 0{,}5$	Clusters por etiquetas (oráculo)	-0.002	0.032	0.003	0.829	5
CIFAR-10, $\alpha = 0{,}5$	Clusters aleatorios	-0.002	0.033	0.005	0.823	5
CIFAR-10, $\alpha = 0{,}5$	Nodos aleatorios	-0.015	0.039	0.007	0.819	5
CIFAR-10, $\alpha = 0{,}5$	Clusters por Δ, sin retener	0.056	0.060	0.008	0.867	5
CIFAR-10, $\alpha = 0{,}5$	Nodos aleatorios, sin retener	0.062	0.068	0.007	0.850	5

Tres hechos se sostienen. (1) El evaluador retenido reduce el RMSE un 41–48 % con clusters por Δ (21–43 % con nodos aleatorios) y lleva el sesgo de $+0{,}04$–$+0{,}14$ a valores entre $-0{,}04$ y $+0{,}01$ en los tres regímenes. (2) Los clusters por Δ capturan estructura de etiquetas sin verlas: la fracción de varianza de la distribución de clases que explican es 0.71 con $\alpha = 0{,}1$ (0.80 el oráculo con etiquetas, 0.10 el azar) y 0.48 con $\alpha = 0{,}5$ (0.62 el oráculo); con $\alpha = 0{,}1$ igualan al oráculo en RMSE. (3) Frente a muestrear nodos al azar, el RMSE de los clusters por Δ es menor en Fashion-MNIST ($+0{,}047$ de diferencia pareada con IC $[0{,}024, 0{,}076]$ para $\alpha = 0{,}1$, mejor en 5/5 semillas; $+0{,}022$ $[0{,}003, 0{,}041]$ para $\alpha = 0{,}5$) y no se detecta diferencia en CIFAR-10 con modelos sin entrenar. Pero el *ranking* no mejora: τ va de 0.82 a 0.97 en todas las variantes y regímenes,

sin diferencias claras entre ellas. Por tanto el estimador es más exacto, no más ordenador.

5.3. Búsqueda de frentes (E3)

Fashion-MNIST, $\alpha = 0{,}1$, $N = 100$, $C = 10$, población 10, 8 generaciones (150 evaluaciones, 30 000 entrenamientos locales de búsqueda por corrida y método, idénticos). Cuatro métodos con la misma partición, sonda y semilla (la búsqueda aleatoria con clusters y la búsqueda aleatoria con nodos aleatorios evalúan exactamente las mismas 150 arquitecturas por semilla; los dos NSGA-II comparten su población inicial, que difiere de la de las búsquedas aleatorias, lo que explica que su HV en la generación 0 difiera): CS-NSGA (la propuesta), NSGA-II con 10 nodos al azar por generación, búsqueda aleatoria con los mismos clusters y, como control, búsqueda aleatoria con nodos aleatorios.

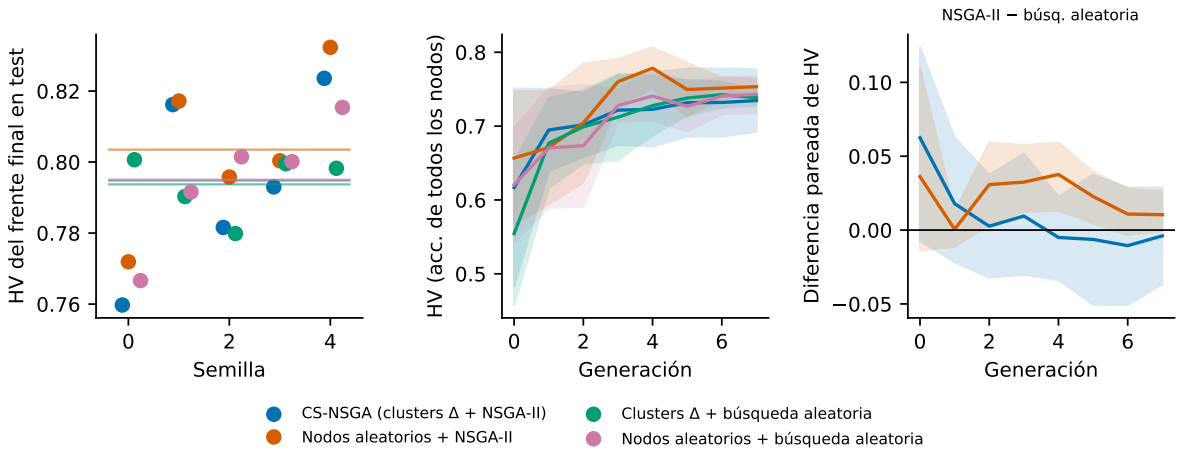


Figura 3: Izquierda: HV del frente final en test por semilla (líneas: medias). Centro: HV del archivo con la accuracy de todos los nodos por generación (media ± DE). Derecha: diferencia pareada por semilla de ese HV entre NSGA-II y la búsqueda aleatoria con el mismo muestreo de nodos (azul: clusters; naranja: nodos aleatorios), por generación (banda: IC bootstrap al 95 % sobre 5 semillas; 0 = sin diferencia). La búsqueda aleatoria parte de otra población inicial, por lo que las diferencias de las primeras generaciones reflejan en parte el azar de esa población.

Tabla 2: E3: frente final reevaluado en test (media ± DE, 5 semillas) y calidad del estimador durante la búsqueda.

Método	HV test	HV todos los nodos	RMSE est.	τ est.	Entren. locales
CS-NSGA (clusters Δ + NSGA-II)	0.795 ± 0.026	0.735	0.043	0.908	30000
Clusters Δ + búsqueda aleatoria	0.794 ± 0.009	0.738	0.045	0.893	30000
Nodos aleatorios + NSGA-II	0.804 ± 0.023	0.753	0.077	0.883	30000
Nodos aleatorios + búsqueda aleatoria	0.795 ± 0.018	0.743	0.077	0.867	30000

Tabla 3: E3: diferencias pareadas por semilla (IC bootstrap sobre 5 semillas; descriptivo).

Contraste	Métrica	Diferencia	IC 95 %	A favor
CS-NSGA − NSGA-II nodos aleat.	HV test	-0.009	[-0.012, -0.005]	0/5
CS-NSGA − NSGA-II nodos aleat.	HV todos (final)	-0.019	[-0.055, 0.017]	3/5
CS-NSGA − NSGA-II nodos aleat.	Área bajo la curva	-0.021	[-0.060, 0.018]	2/5
NSGA-II nodos aleat. − búsq. aleat. nodos aleat.	HV test	0.008	[-0.001, 0.019]	4/5
NSGA-II nodos aleat. − búsq. aleat. nodos aleat.	HV todos (final)	0.010	[-0.001, 0.027]	4/5
NSGA-II nodos aleat. − búsq. aleat. nodos aleat.	Área bajo la curva	0.023	[0.016, 0.029]	5/5
CS-NSGA − búsq. aleat. clusters	HV test	0.001	[-0.021, 0.021]	3/5
CS-NSGA − búsq. aleat. clusters	HV todos (final)	-0.004	[-0.037, 0.029]	3/5
CS-NSGA − búsq. aleat. clusters	Área bajo la curva	0.008	[-0.027, 0.038]	3/5
búsq. aleat. clusters − búsq. aleat. nodos aleat.	HV test	-0.001	[-0.017, 0.017]	1/5
búsq. aleat. clusters − búsq. aleat. nodos aleat.	HV todos (final)	-0.004	[-0.022, 0.013]	1/5
búsq. aleat. clusters − búsq. aleat. nodos aleat.	Área bajo la curva	-0.007	[-0.018, 0.005]	1/5
NSGA-II nodos aleat. − búsq. aleat. clusters	HV test	0.010	[-0.011, 0.028]	4/5
NSGA-II nodos aleat. − búsq. aleat. clusters	HV todos (final)	0.015	[0.009, 0.023]	5/5
NSGA-II nodos aleat. − búsq. aleat. clusters	Área bajo la curva	0.029	[0.013, 0.045]	4/5

La propuesta no mejora el frente. Frente a NSGA-II con nodos aleatorios es ligeramente peor, y de forma consistente (la desviación pareada es de solo 0.005): −0,009 de HV (≈1 %) con 0 de 5 semillas a favor. **Sí hay evolución en las curvas, y su atribución depende del muestreo.** El HV del archivo con la accuracy de todos los nodos sube de la generación 0 a la 7 en los cuatro métodos (Figura 3, centro): +0,118 con CS-NSGA (mejora en 4/5 semillas), +0,097 con NSGA-II y nodos aleatorios (5/5), +0,184 con la búsqueda aleatoria con clusters y +0,122 con la búsqueda aleatoria con nodos aleatorios (5/5 ambas), que parten de poblaciones iniciales distintas. Con los mismos clusters, la diferencia pareada entre NSGA-II y búsqueda aleatoria es compatible con cero en todas las generaciones (de +0,018 en la generación 1 a −0,004 en la 7; Figura 3, derecha, azul) y en el área bajo la curva (+0,008, [−0,027, +0,038]). Con nodos aleatorios, en cambio, NSGA-II queda por encima de la búsqueda aleatoria en el área bajo la curva en las 5 semillas (+0,023, [+0,016, +0,029]; Figura 3, derecha, naranja) y por poco en el HV final (test +0,008, [−0,001, +0,019], 4/5; todos los nodos +0,010, [−0,001, +0,027], 4/5): un efecto pequeño (hasta ≈3 % del HV medio) pero consistente. Que el muestreo por clusters no tenga búsqueda aleatoria distinta del muestreo aleatorio (−0,001, [−0,017, +0,017]) sugiere que la diferencia aparece en la combinación con NSGA-II; una explicación coherente con el estudio de ruido, no probada, es que a $C = 10$ los clusters dan modelos más ruidosos y sesgados que los nodos aleatorios, lo que degrada la selección. El HV por generación se calcula sobre el frente que elige cada algoritmo con su estimación ruidosa, por lo que no es monótono. La diferencia mínima detectable de este diseño para un contraste con una desviación pareada como la de CS-NSGA frente a la búsqueda con clusters es de ≈ 0,046 (5.7 % del HV con 80 % de potencia), de modo que efectos menores no se habrían visto en ese contraste. Conviene además no usar el HV calculado con la accuracy estimada por los representantes: favorece a los nodos aleatorios (0.837 frente a 0.771) y esa ventaja desaparece con la accuracy de todos los nodos y con test, un caso de optimismo por selección sobre un estimador más ruidoso.

5.4. Por qué: paisaje con estructura y fitness ruidoso

El paisaje no es plano. Entre 150 arquitecturas aleatorias por semilla la accuracy media es 0.38 con desviación 0.157 y rango 0.06–0.76; solo el 1 % está a $\leq$ 0,02 de la mejor y el 3 % a $\leq$ 0,05. Los genes explican el 65 % de la varianza (validación cruzada de un bosque aleatorio), sobre todo el número de bloques y el dropout. Hay, pues, estructura que una búsqueda dirigida podría explotar.

El ruido del fitness es del tamaño de la banda de las mejores. Entrenar la misma arquitectura con otros 10 nodos cambia su accuracy global en ±0,058 (a partir de las reevaluaciones

del propio E3) frente a 0.18 de desviación entre arquitecturas, igual con clusters que con nodos aleatorios. Un estudio específico (20 arquitecturas aleatorias, 4 sorteos de los nodos de entrenamiento, una partición) lo cuantifica por número de nodos (Figura 4, Tabla 4).

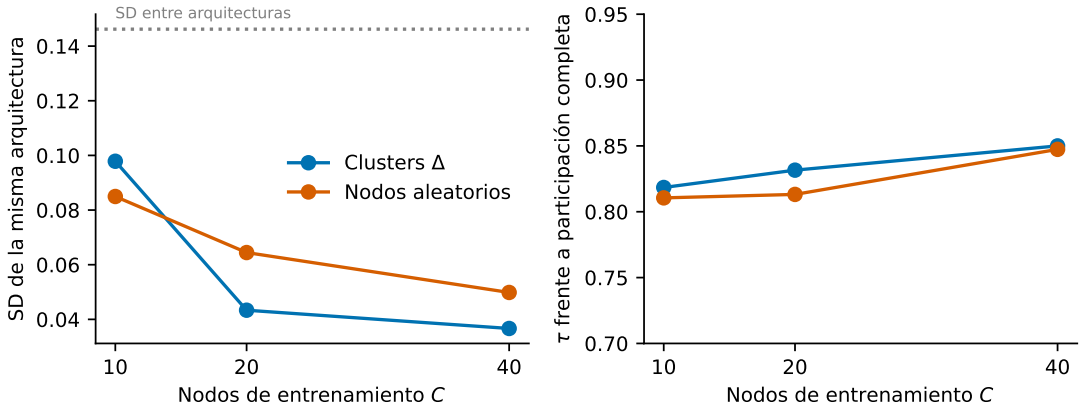


Figura 4: Izquierda: desviación de la accuracy de una misma arquitectura al cambiar los nodos de entrenamiento. Derecha: Kendall τ frente a la accuracy con participación completa (un sorteo).

Tabla 4: Ruido por nodos de entrenamiento (20 arquitecturas $\times$ 4 sorteos, Fashion-MNIST, $\alpha = 0{,}1$).

Variante	SD misma arq.	Ruido/señal	τ test-retest	τ vs completa	Sesgo vs completa	RMSE vs completa
Clusters Δ, $C = 10$	0.098	0.695	0.746	0.818	-0.166	0.195
Clusters Δ, $C = 20$	0.043	0.283	0.796	0.832	-0.083	0.101
Clusters Δ, $C = 40$	0.037	0.243	0.830	0.850	-0.067	0.082
Nodos aleatorios, $C = 10$	0.085	0.650	0.747	0.811	-0.113	0.145
Nodos aleatorios, $C = 20$	0.064	0.442	0.819	0.813	-0.064	0.095
Nodos aleatorios, $C = 40$	0.050	0.321	0.825	0.847	-0.026	0.063

Con $C = 10$ el ruido es el más alto (relación ruido/señal ≈0.65–0.70 en esta muestra; ≈0.32 con los datos de E3, discrepancia no reconciliada por tratarse de conjuntos de arquitecturas distintos). Pasar a $C = 20$ lo reduce a menos de la mitad con clusters (0.098→0.043) y mucho menos con nodos aleatorios (0.085→0.064); de 20 a 40 apenas cambia. Agrupar por Δ reduce el ruido solo con $C \geq 20$. Sin embargo, el orden frente a participación completa casi no mejora con C ($\tau \approx 0{,}81$–$0{,}85$) y, entre arquitecturas separadas por menos de 0.05, se acierta el orden en solo el 61–72 % de los pares sin tendencia clara con C ni con el método. Entrenar con pocos nodos además subestima la accuracy (entre $-0{,}03$ y $-0{,}17$). Todo ello encaja con el resultado de E3: a $C = 10$ los clusters no reducen el ruido de entrenamiento y se alejan más de la accuracy completa que los nodos aleatorios; su ventaja es de *evaluación*, no de entrenamiento. Es una explicación coherente, no una prueba: E3 con $C = 20$ no se ha ejecutado.

5.5. Cohesión de los clusters y alternativas de agrupación

Se revisó, sin entrenar arquitecturas y con la misma sonda y semillas de E3, si los nodos que quedan juntos están realmente relacionados (Tabla 5). **Tamaños.** Los clusters por Δ ya no son de tamaño uniforme: con $C = 10$ y $\alpha = 0{,}1$ van de 5 a 17 nodos (mínimo medio 6.2, máximo medio 14.6) y no aparece ninguno de un solo nodo. **Cohesión.** La distancia de Hellinger entre distribuciones de clases es 0.54 dentro de un cluster frente a 0.83 en una agrupación aleatoria (0.50 con el oráculo de etiquetas), y la pureza de la clase dominante es 0.78 (0.96 el oráculo); sin embargo los clusters no están claramente separados en el espacio Δ (silueta 0.21). Los clusters grandes son menos cohesivos (correlación 0.38 entre tamaño y dispersión de etiquetas). Con

$\alpha = 0{,}5$ la cohesión es menor ($\eta^2 = 0{,}46$). **Estabilidad.** Es moderada: con otra inicialización de la sonda el acuerdo entre agrupaciones es ARI $= 0{,}54$ y con otra semilla de k-means sobre los mismos Δ, 0.68; la reconstrucción es idéntica solo con el mismo número de hilos de cómputo, por no determinismo numérico de la sonda (el η^2 de 0.68 de esta reconstrucción difiere ligeramente del 0.71 del estudio de estimador por esa variabilidad).

Tabla 5: Cohesión de las agrupaciones con $C = 10$ (Fashion-MNIST, $N = 100$, media de 5 semillas). Dist. etiquetas: distancia de Hellinger entre distribuciones de clases; Var. relativa: varianza de un proxy del estimador (distribución de etiquetas) frente a C nodos al azar.

α	Agrupación	Tamaños mín/med/máx	η^2	Dist. etiquetas dentro / entre	Pureza	Var. relativa del estimador
0.100	k-means sobre Δ (usada)	6.2 / 9.9 / 14.6	0.678	0.54 / 0.86	0.777	0.395
0.100	Oráculo con etiquetas	6.4 / 9.6 / 14.6	0.800	0.50 / 0.86	0.961	0.242
0.100	Enlace promedio sobre Δ (tamaño libre)	1.8 / 9.2 / 20.4	0.649	0.57 / 0.86	0.792	0.571
0.100	Aleatoria	10.0 / 10.0 / 10.0	0.095	0.83 / 0.83	0.282	0.995
0.500	k-means sobre Δ (usada)	5.8 / 9.7 / 14.6	0.464	0.46 / 0.60	0.513	0.649
0.500	Oráculo con etiquetas	6.0 / 10.0 / 14.8	0.617	0.45 / 0.60	0.856	0.457
0.500	Enlace promedio sobre Δ (tamaño libre)	2.0 / 10.4 / 19.8	0.449	0.47 / 0.60	0.560	0.862
0.500	Aleatoria	10.0 / 10.0 / 10.0	0.083	0.59 / 0.58	0.262	1.009

Alternativas. Se probaron sin entrenar, con un proxy de la varianza del estimador (la distribución de etiquetas de cada nodo como sustituto de lo que determina su accuracy). (i) Dar libertad total de tamaño con un enlace jerárquico promedio genera nodos sueltos y clusters de hasta 20 nodos y empeora el proxy (0.57 frente a 0.40 con k-means). (ii) Repartir más representantes a los clusters grandes o heterogéneos (asignación de Neyman) con presupuesto fijo tampoco ayuda: con 10 representantes, 5 clusters con Neyman dan 0.67 y 10 clusters con un representante cada uno 0.40; con 20 representantes, 10 clusters con Neyman (0.35) equivalen a 20 clusters con uno cada uno (0.36). Subir C reduce el proxy (0.33 con $C = 20$, 0.27 con $C = 40$) a costa de clusters de un solo nodo ($\approx$13 de 40 con $C = 40$). Este proxy no incluye el ruido de entrenamiento, que fue el limitante en E3: dice que los clusters son razonables como estratos, no que vayan a mejorar la búsqueda.

5.6. Refinamiento multifidelidad (E4)

Sobre las 20 corridas de E3 (incluido el control) se reevaluaron los ≤ 12 candidatos más prometedores con $C = 40$ nodos aleatorios nuevos (coste añadido de $\approx$9 600 entrenamientos locales por corrida, el mismo para los cuatro métodos), se eligió el frente final con esa estimación y se reentrenó con participación completa.

Tabla 6: E4: HV del frente final en test antes y después del refinamiento multifidelidad ($C = 40$ sobre ≤ 12 candidatos).

Método	HV original	HV refinado	Cambio pareado	IC 95 %	Mejoran
CS-NSGA (clusters Δ + NSGA-II)	0.795	0.794	-0.001	[-0.010, 0.004]	4/5
Clusters Δ + búsqueda aleatoria	0.794	0.798	0.005	[0.001, 0.009]	5/5
Nodos aleatorios + NSGA-II	0.804	0.812	0.009	[0.001, 0.017]	4/5
Nodos aleatorios + búsqueda aleatoria	0.795	0.794	-0.001	[-0.026, 0.017]	3/5

El refinamiento aporta como mucho +0,005 a +0,009 de HV ($\approx$1 %) en dos de cuatro métodos (NSGA-II con nodos aleatorios y búsqueda aleatoria con clusters) y nada en CS-NSGA ni en la búsqueda aleatoria con nodos aleatorios ($-0{,}001$); no cambia el orden entre métodos (la diferencia CS-NSGA frente a NSGA con nodos aleatorios pasa a $-0{,}019$, $[-0{,}031, -0{,}006]$) y la mejor accuracy de test apenas se mueve ($-0{,}005$ a $+0{,}003$). La estimación refinada correlaciona 0.99 con la accuracy del mismo modelo en todos los nodos (0.92 la de búsqueda con $C = 10$), pero eso no se traduce en mejores frentes con entrenamiento completo: el cuello de botella parece estar en el conjunto de candidatos que genera la búsqueda y en la diferencia entre entrenar con C nodos y con todos.

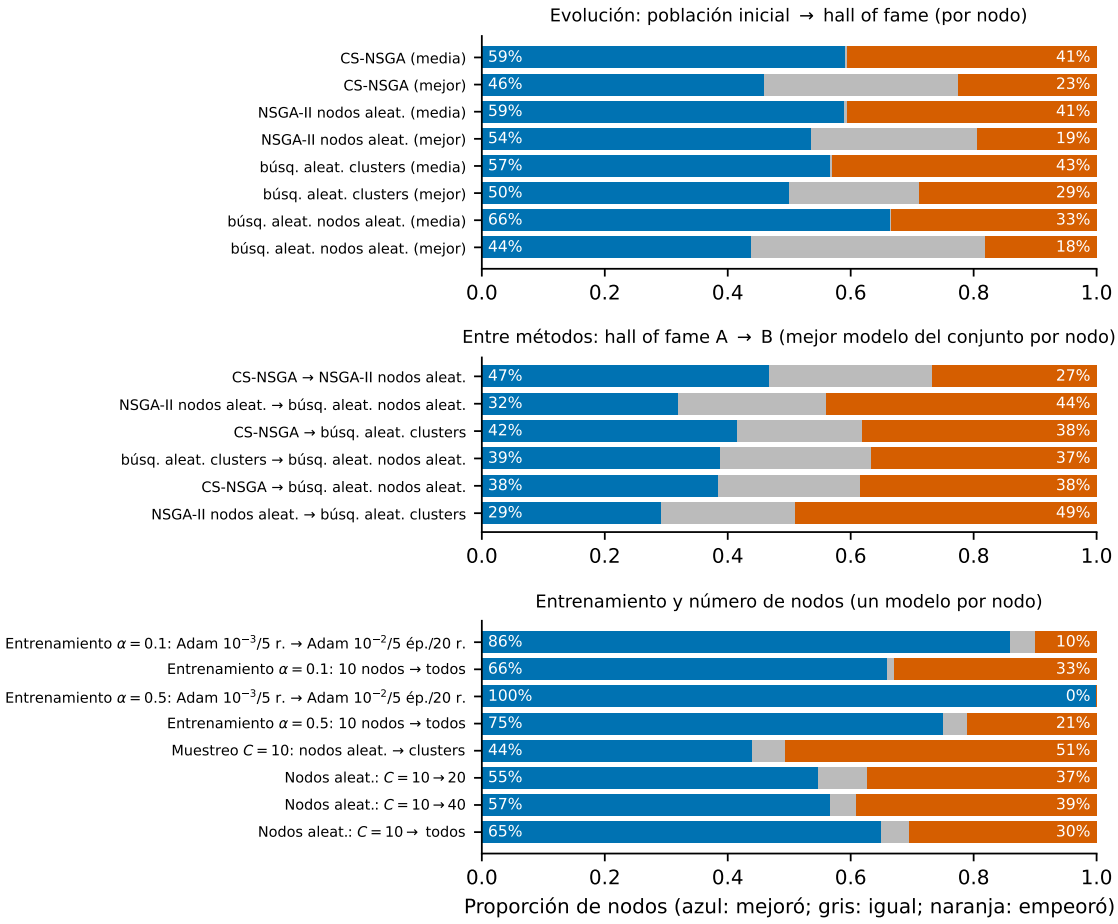


Figura 5: Proporción de nodos que mejoran (azul), quedan igual (gris) o empeoran (naranja). Arriba y centro: E3, media de 5 semillas por método; abajo: diagnóstico de entrenamiento (una arquitectura, una partición) y estudio de ruido (media sobre arquitecturas y sorteos).

5.7. Proporción de nodos que mejoran

Los experimentos anteriores reportan promedios sobre nodos, que pueden ocultar que unos nodos ganen y otros pierdan. Por eso se midió la accuracy *por nodo* (ninguna corrida la había guardado, así que se reentrenaron los modelos; la accuracy media recalculada coincide exactamente con la guardada en las 20 corridas, lo que verifica la reproducibilidad). Un nodo *mejora* si su accuracy es mayor con el modelo B que con el A, *queda igual* si coincide y *empeora* si es menor; "no mejora" es igual más empeora. En E3 se compara la población inicial (las 10 arquitecturas de la generación 0) con el hall of fame final (el frente de Pareto: todas las arquitecturas no dominadas entre lo evaluado, de 6 a 15 por corrida), todas entrenadas con los 100 nodos y medidas en prueba; como son conjuntos de modelos se usa la accuracy media del nodo sobre el conjunto ("media") y, como control, la mejor del conjunto para ese nodo ("mejor"). La Figura 5 y las Tablas 7 y 8 resumen los resultados.

Tabla 7: Proporción de nodos que mejoran, quedan igual o empeoran en E3 (media ± DE entre las 5 semillas; accuracy por nodo en prueba con modelos entrenados con los 100 nodos). "media" y "mejor": accuracy media o máxima del nodo sobre el conjunto de modelos.

Comparación	Mejoró %	Igual %	Empeoró %	Cambio medio (pp)	n
CS-NSGA (media)	59 ± 43	0 ± 0	41 ± 44	+1.8	5
CS-NSGA (mejor)	46 ± 19	31 ± 12	23 ± 13	+1.7	5
NSGA-II nodos aleat. (media)	59 ± 41	0 ± 1	41 ± 41	+3.0	5
NSGA-II nodos aleat. (mejor)	54 ± 14	27 ± 11	19 ± 13	+4.1	5
búsq. aleat. clusters (media)	57 ± 32	0 ± 1	43 ± 32	+1.8	5
búsq. aleat. clusters (mejor)	50 ± 15	21 ± 7	29 ± 13	+2.0	5
búsq. aleat. nodos aleat. (media)	66 ± 24	0 ± 0	33 ± 24	+3.5	5
búsq. aleat. nodos aleat. (mejor)	44 ± 18	38 ± 25	18 ± 17	+2.2	5
CS-NSGA → NSGA-II nodos aleat.	47 ± 15	26 ± 9	27 ± 10	+2.5	5
NSGA-II nodos aleat. → búsq. aleat. nodos aleat.	32 ± 17	24 ± 6	44 ± 15	-1.6	5
CS-NSGA → búsq. aleat. clusters	42 ± 16	20 ± 6	38 ± 12	+0.7	5
búsq. aleat. clusters → búsq. aleat. nodos aleat.	39 ± 9	25 ± 6	37 ± 10	+0.2	5
CS-NSGA → búsq. aleat. nodos aleat.	38 ± 14	23 ± 4	38 ± 10	+0.9	5
NSGA-II nodos aleat. → búsq. aleat. clusters	29 ± 16	22 ± 4	49 ± 16	-1.8	5

Tabla 8: Proporción de nodos que mejoran en el diagnóstico de entrenamiento (una arquitectura y una partición, $n = 1$) y en el estudio de ruido (media ± DE entre arquitecturas y sorteos).

Comparación	Mejoró %	Igual %	Empeoró %	Cambio medio (pp)	n
Entrenamiento $\alpha = 0{,}1$: Adam 10^{-3}/5 r. → Adam 10^{-2}/5 ép./20 r.	86	4	10	+27.3	1
Entrenamiento $\alpha = 0{,}1$: 10 nodos → todos	66	1	33	+17.8	1
Entrenamiento $\alpha = 0{,}5$: Adam 10^{-3}/5 r. → Adam 10^{-2}/5 ép./20 r.	100	0	0	+51.9	1
Entrenamiento $\alpha = 0{,}5$: 10 nodos → todos	75	4	21	+3.1	1
Muestreo $C = 10$: nodos aleat. → clusters	44 ± 12	5 ± 4	51 ± 10	-1.8	20
Nodos aleat.: $C = 10 \rightarrow 20$	55 ± 14	8 ± 8	37 ± 12	+6.6	20
Nodos aleat.: $C = 10 \rightarrow 40$	57 ± 13	4 ± 4	39 ± 12	+10.2	20
Nodos aleat.: $C = 10 \rightarrow$ todos	65 ± 15	4 ± 6	30 ± 11	+13.8	20

Evolución. Del conjunto inicial al hall of fame mejora el 60 % de los nodos con la accuracy media del conjunto (el 52 % por más de 2 puntos), empeora el 39 % (31 % por más de 2 puntos) y casi ninguno queda igual; con el mejor modelo del conjunto mejora el 48 %, queda igual el 29 % y empeora el 22 %. El cambio medio es de +2,5 puntos. Por método, con la media del conjunto mejoran el 59 % (CS-NSGA), 59 % (NSGA-II con nodos aleatorios), 57 % (búsqueda aleatoria con clusters) y 66 % (búsqueda aleatoria con nodos aleatorios): la búsqueda evolutiva no mejora a más nodos que la aleatoria. Entre semillas la proporción varía mucho (desviación de 0.24 a 0.43), y entre los nodos del cuartil más débil mejora el 77 % (con la regresión a la media a favor). **Entre métodos** (mejor del conjunto) los contrastes están cerca del reparto parejo: de CS-NSGA a NSGA-II con nodos aleatorios mejoran el 47 % y empeora el 27 % (el resto queda igual); de NSGA-II con nodos aleatorios a la búsqueda aleatoria con los mismos nodos mejora el 32 % y empeora el 44 %, coherente con que NSGA-II con nodos aleatorios sea el método con mejores cifras. **Refinamiento.** Del hall of fame original al refinado mejora el 38 % de los nodos y empeora el 61 % (cambio medio −1,1 puntos); con el mejor modelo del conjunto ninguno mejora, porque el refinado se elige entre candidatos del mismo conjunto de la búsqueda.

¿Hay arquitecturas del hall of fame que mejoren a todos los nodos? Prácticamente no (Tabla 9). De las 205 arquitecturas del hall of fame en las 20 corridas, solo 2 superan a los 100 nodos respecto a la accuracy media de la población inicial (una era nueva) y ninguna lo hace frente al mejor modelo inicial: la mejor alcanza el 90 % de los nodos y la mediana es del 8 %. Frente al mejor modelo inicial de cada nodo, el más exigente, el máximo es del 67 %. Los 6 casos de "ningún nodo peor" frente al mejor modelo inicial son ese mismo modelo, que ya estaba en el hall of fame. Comparando el mejor modelo de cada conjunto, en 5 de las 20 corridas el mejor del hall of fame es el propio mejor modelo inicial; en las otras 15 mejora de media al 51 % de

los nodos (entre 21 y 90 %) y su accuracy media es mayor en 8 corridas y menor en 7. Cuando la evolución encuentra un modelo mejor, el beneficio es parcial: gana una parte de los nodos y otra pierde, y ninguna arquitectura domina nodo a nodo. Parte de esa dispersión es ruido de medición por nodo, y el hall of fame incluye por construcción modelos pequeños que no buscan maximizar la accuracy.

Tabla 9: Arquitecturas del hall of fame (205 en 20 corridas, 20 ya presentes en la población inicial) frente a distintas referencias de la población inicial, por nodo.

Referencia	Mejoran a todos los nodos	Ningún nodo peor	Mediana de nodos que mejoran	Máximo	$\geq 90\,\%$ de nodos
Accuracy media de la población inicial (por nodo)	2	4	70 %	100 %	86
Mejor modelo inicial (por accuracy media)	0	6	8 %	90 %	1
Mejor modelo inicial de cada nodo	0	0	2 %	67 %	0

Entrenamiento y número de nodos. La mejora de configuración de FedAvg (de Adam 10^{-3} con 5 rondas a Adam 10^{-2} con 5 épocas y 20 rondas) beneficia al 86 % de los nodos con $\alpha = 0{,}1$ y al 100 % con $\alpha = 0{,}5$. Pasar de entrenar con 10 nodos a entrenar con todos mejora el 66 % de los nodos y empeora el 33 % con $\alpha = 0{,}1$ (el 75 % y el 21 % con $\alpha = 0{,}5$), aunque el promedio sube +17,8 y +3,1 puntos: aun con participación completa, un tercio de los nodos queda peor. En el estudio de ruido, subir de $C = 10$ a $C = 40$ nodos aleatorios mejora el 57 % de los nodos (empeora el 39 %), y a participación completa el 65 % (30 %). Con el mismo $C = 10$, entrenar con representantes por clusters en lugar de nodos aleatorios mejora solo el 44 % de los nodos y empeora el 51 % ($-1{,}8$ puntos), en línea con el sesgo de entrenamiento medido antes.

Cautelas. Cada nodo se mide con pocas muestras de prueba (de unas decenas a unos cientos), por lo que cambios pequeños son ruido; por eso se incluyen las proporciones con cambios de más de 2 puntos. La accuracy "media" sobre un frente mezcla modelos pequeños y grandes (el hall of fame cubre todo el compromiso con los parámetros), de modo que "mejor" es la comparación más justa entre frentes. Las proporciones no tienen intervalos más allá de la desviación entre semillas (5) o entre arquitecturas, y el diagnóstico de entrenamiento usa una sola arquitectura y partición. Los análisis sin modelos nuevos (estimador, paisaje y clusters) no tienen una versión por nodo.

6. Discusión

Qué se sostiene. Evaluar en un nodo retenido del cluster es un cambio sencillo y reproducido en cuatro estudios que reduce el sesgo y el error de un estimador de fitness basado en pocos nodos; los clusters por actualizaciones aproximan a los de etiquetas sin revelar etiquetas, algo que, según nuestra lectura, los grupos balanceados por distribución de etiquetas de [2] no ofrecen. **El mejor método en promedio es el más simple.** NSGA-II con nodos aleatorios obtiene el mayor HV en test (0.804 frente a 0.795, 0.794 y 0.795), con el HV de todos los nodos (0.753 frente a 0.735, 0.739 y 0.743), tras el refinamiento (0.812) y en el área bajo la curva de HV. Su ventaja sobre CS-NSGA es pequeña ($\approx$1 %) pero consistente (0 de 5 semillas a favor de CS-NSGA). Frente a la búsqueda aleatoria con el mismo muestreo (el control que cierra la confusión anterior) la ventaja es pequeña y consistente en el área bajo la curva (5/5) y sugerente en el HV final. La parte de clusters de la propuesta no ayuda a la búsqueda en este régimen, y la evolución parece aportar algo solo cuando el muestreo es aleatorio. **Qué no.** Esa mejora de la evaluación no se tradujo en mejores frentes: a $C = 10$ el limitante es el ruido del fitness por *qué nodos entrenan*, que ni la estratificación ni el refinamiento posterior corrigen, y que impide ordenar bien a las mejores arquitecturas con una sola evaluación. Es coherente con la advertencia de [4] sobre la validación ruidosa con pocos clientes, que aquí se cuantifica y se descompone entre evaluación y entrenamiento. **Relación con la literatura.** En espacios mucho mayores la búsqueda aleatoria sí pierde frente a una dirigida a igual presupuesto [6]; nuestro espacio es pequeño y el presupuesto bajo, lo que puede explicar que el efecto de NSGA-II sea pequeño, pero este informe no lo prueba.

7. Relación con los vacíos de la revisión sistemática

La revisión previa (`manuscript/main.pdf`; una sola base de datos, un revisor, cribado por resúmenes y 13 textos completos) señaló los vacíos de la Tabla 10. Lo que sigue vale para ese corpus; la afirmación de que nadie había probado la selección por similitud de actualizaciones en la evaluación de candidatos de NAS requeriría repetir la búsqueda en otras bases antes de sostenerse como novedad.

Tabla 10: Vacíos de la revisión y lo que aportan los experimentos de este informe.

Vacío	¿Abordado?	Resultado
Elegir clientes por similitud de *actualizaciones* para evaluar candidatos (la literatura usa selección aleatoria o grupos por distribución de etiquetas)	Sí, se probó	Estimador más exacto que el aleatorio, pero sin mejor búsqueda con $C = 10$; respuesta mayormente negativa, con un dataset, $\alpha = 0{,}1$ y 5 semillas.
Medir cuánto se distorsiona el ranking de candidatos con pocos clientes (señalado como problema en [4], no medido)	Sí; es el aporte más claro	Descomposición del error entre evaluación y entrenamiento; el ruido por qué nodos entrenan (±0,06–0,10) es comparable a la banda de las mejores; $\tau \approx 0{,}85$ frente a participación completa y 61–72 % de acierto entre arquitecturas cercanas.
Rigor de evaluación (repeticiones, separación validación/prueba por nodo, hipervolumen, costes)	Parcialmente	Validación y prueba por nodo, 5 semillas pareadas, costes separados y HV en test con participación completa; pero solo 5 semillas y una semilla de inicialización en el test final.
Heterogeneidad habitual suave	Parcialmente	$\alpha = 0{,}1$ y 0,5; la búsqueda (E3) solo con $\alpha = 0{,}1$.
Baselines aleatorios	Sí	Búsqueda aleatoria con y sin clusters y muestreo aleatorio de nodos.
Objetivo de peor cliente en la búsqueda	No	Se dejó fuera del algoritmo (solo monitoreo).

8. Limitaciones y amenazas a la validez

- Cinco semillas por contraste; los intervalos bootstrap sobre cinco valores son descriptivos. La evolución no podría haberse detectado por debajo de ≈5.7 % de HV.
- El frente final se reevalúa con una sola semilla de inicialización y como máximo 5 arquitecturas por frente; E3 y E4 usan un solo conjunto de datos, un solo α (0.1) y $C = 10$.
- Los estudios de estimador y ruido usan arquitecturas aleatorias, no las que genera una búsqueda; el estudio de ruido usa una sola partición y 20 arquitecturas, y sus desviaciones y τ son estimaciones ruidosas sin intervalos.
- Espacio de búsqueda pequeño; presupuesto de 150 evaluaciones; no se ablacionó la ponderación por tamaño de cluster ni el método de agrupamiento.
- El refinamiento ocurre tras la búsqueda y no la guía; no se probó el fitness acumulado entre generaciones ni *successive halving* dentro de la búsqueda.
- Se corrigió a tiempo un error propio en el script de análisis del estudio de ruido (alineación de arquitecturas en el cálculo de τ); las cifras presentadas son las corregidas.

9. Conclusiones y trabajo futuro

CS-NAS, tal como se implementó y con el régimen y presupuesto probados, no mejora la búsqueda de arquitecturas frente a muestrear nodos al azar (es ligeramente peor que NSGA-II con nodos aleatorios) y la evolución no se distingue de la búsqueda aleatoria cuando se usan clusters. Con muestreo aleatorio de nodos, NSGA-II supera a la búsqueda aleatoria por un

margen pequeño pero consistente en el área bajo la curva de HV (5/5 semillas) y sugerente en el HV final. El método con mejores cifras es, por tanto, NSGA-II con nodos aleatorios. El resultado útil es de diagnóstico: el evaluador retenido, un estimador por clusters de Δ más exacto que el aleatorio, y la caracterización del ruido de fitness por nodos de entrenamiento como cuello de botella. Los siguientes pasos de mayor valor informativo son: (1) repetir E3 con $C = 20$ y más semillas, la única prueba directa de que el ruido era el obstáculo (el doble de coste); (2) fitness multifidelidad *dentro* de la búsqueda (acumular evaluaciones de los padres, descarte temprano); (3) un espacio de búsqueda mayor o un segundo conjunto de datos, donde la evolución tendría más margen.

10. Reproducibilidad

Rama `experiment/cluster-sampling-nas`; el código de las propuestas anteriores está en la etiqueta `legacy-final` y sus resultados en `~/Desktop/evofederated_legacy_results.tar.gz`. Los resultados de este informe están en `runs/` (no versionado; copia en `~/Desktop/evofederated_cs_nas_runs.t` y las decisiones y resultados detallados en `docs/` (`PROTOCOL`, `E3_DESIGN`, `E4_DESIGN`, `RESULTS_*`, `ANALISIS_CONSOLIDADO`); la cohesión de clusters se reproduce con `analyze_clusters.py`, `analyze_cluster_stability.py` y `analyze_allocation.py`. Código: `run_cs.py` (una corrida), `run_estimator_study.py`, `run_training_diagnostic.py`, `run_noise_study.py`, `run_refine.py` y los `analyze_*.py`; las figuras y tablas de este informe se generan con `manuscript/make_report_assets.py` a partir de `runs/`. Las semillas de cada corrida se guardan en su `config.json`. El código, los documentos y el informe están confirmados y publicados en la rama `experiment/cluster-sampling-nas` del repositorio remoto; `runs/` no se versiona.

Referencias

[1] Hangyu Zhu and Yaochu Jin. Real-Time Federated Evolutionary Neural Architecture Search. *IEEE Transactions on Evolutionary Computation*, 26:364–378, 2021.

[2] Jinliang Yuan, Mengwei Xu, Yuxin Zhao, Kaigui Bian, Gang Huang, Xuanzhe Liu, and Shangguang Wang. Resource-Aware Federated Neural Architecture Search over Heterogeneous Mobile Devices. *IEEE Transactions on Big Data*, pages 1–11, 2022.

[3] Rahul Atul Bhope, K. R. Jayaram, Nalini Venkatasubramanian, Ashish Verma, and Gegi Thomas. FLIPS: Federated Learning using Intelligent Participant Selection. arXiv (Cornell University), 2023.

[4] Mikhail Khodak, Renbo Tu, Tian Li, Liam Li, Maria-Florina Balcan, Virginia Smith, and Ameet Talwalkar. Federated Hyperparameter Tuning: Challenges, Baselines, and Connections to Weight-Sharing. arXiv (Cornell University), 2021.

[5] Kalyanmoy Deb, Amrit Pratap, Sameer Agarwal, and T. Meyarivan. A fast and elitist multiobjective genetic algorithm: NSGA-II. *IEEE Transactions on Evolutionary Computation*, 6:182–197, 2002.

[6] ukasz Dudziak, Stefanos Laskaridis, and Javier Fernandez-Marques. FedorAS: Federated Architecture Search under system heterogeneity. arXiv (Cornell University), 2022.